TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT THÀNH PHỐ HỒ CHÍ MINH

KHOA CÔNG NGHỆ THÔNG TIN — KHOA KINH TẾ

BÁO CÁO ĐỒ ÁN MÔN HỌC

PHÂN TÍCH DỮ LIỆU LỚN TRONG KINH DOANH

Mã học phần: ABDA433708

ĐỀ TÀI

BEAUTYPRICE INTELLIGENCE

Thu thập, phân tích và dự đoán giá mỹ phẩm từ 5 nhà bán lẻ trực tuyến tại Việt Nam

Thông tin	Nội dung
Giảng viên hướng dẫn	«Điền họ tên giảng viên»
Lớp học phần	ABDA433708_«xx»
Năm học	Học kỳ «x», năm học «20xx-20xx»
Nhóm thực hiện	Nhóm «số thứ tự nhóm»
Số thành viên	5 sinh viên
Kho mã nguồn	https://github.com/Mthu06/beautyprice-analytics

Thành phố Hồ Chí Minh, tháng 10 năm 2026

BẢNG PHÂN CÔNG CÔNG VIỆC

Bảng dưới đây ghi rõ phần việc của từng thành viên. Cột "Tài khoản Git" dùng để đối chiếu với lịch sử commit trên kho mã nguồn của nhóm.

STT	Họ và tên	MSSV	Tài khoản Git	Nội dung phụ trách
1	«Điền họ tên» (Nhóm trưởng)	24126228	Mthu06	Tích hợp hệ thống, website, công cụ thu thập
2	«Điền họ tên»	24126231	TrMinhThu	Phân tích khám phá dữ liệu và dashboard
3	«Điền họ tên»	24126224	NgBichThuy	Mô hình học máy
4	«Điền họ tên»	«Điền MSSV»	PDat	Thiết kế cơ sở dữ liệu và lưu trữ
5	«Điền họ tên»	«Điền MSSV»	NTPThuy	Dữ liệu thu thập ban đầu

Chi tiết công việc theo từng giai đoạn:

Giai đoạn	Phụ trách	Công việc cụ thể	Kết quả
Thu thập dữ liệu ban đầu	NTPThuy	Thu thập dữ liệu sản phẩm từ website, lưu dạng CSV	dataset/legacy/
Giai đoạn 5 Thiết kế CSDL	PDat	Phân tích đối tượng, thiết kế lược đồ quan hệ, ràng buộc, viết tài liệu thiết kế và kiểm tra CSDL	THIET_KE_CSDL.md, KIEM_TRA_CSDL.md
Giai đoạn 6 EDA và dashboard	TrMinhThu	Phân tích khám phá dữ liệu, xây dựng bộ chỉ số KPI, vẽ biểu đồ, viết nhận định	source-code/analysis/
Giai đoạn 7 Học máy	NgBichThuy	Xây dựng 4 nhóm mô hình, so sánh và chọn mô hình, viết báo cáo kết quả	train_models.py, KET_QUA_MO_HINH.md
Giai đoạn 8 Website	Mthu06	Xây dựng backend và giao diện 9 màn hình, phân quyền, CRUD, sao lưu phục hồi, kiểm thử	backend/, frontend/, tests/
Công cụ thu thập (điểm cộng)	Mthu06	Xây dựng công cụ thu thập đa nguồn, tích hợp vào website kèm lịch tự động	crawler/crawl.py

Giai đoạn	Phụ trách	Công việc cụ thể	Kết quả
Tổng hợp	Cả nhóm	Rà soát lỗi, viết tài liệu, chuẩn bị báo cáo và slides	reports/

Ghi chú: mỗi thành viên commit phần việc của mình lên kho mã nguồn chung. Tài liệu reports/GIAI_THICH_CODE.md giải thích chi tiết từng tệp và từng hàm, dùng để chuẩn bị cho phần vấn đáp.

MỤC LỤC

BẢNG PHÂN CÔNG CÔNG VIỆC 2
MỤC LỤC 4
CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI 6
1.1. Bối cảnh và lý do chọn đề tài 6
1.2. Mục tiêu đề tài 6
1.3. Phạm vi và giới hạn 6
1.4. Công nghệ sử dụng 7
1.5. Kiến trúc tổng thể 7
CHƯƠNG 2. THU THẬP DỮ LIỆU VÀ THIẾT KẾ CƠ SỞ DỮ LIỆU 9
2.1. Phân tích đối tượng dữ liệu 9
2.2. Quy tắc nghiệp vụ 9
2.3. Lựa chọn hệ quản trị cơ sở dữ liệu 10
2.4. Lược đồ cơ sở dữ liệu 10
2.5. Công cụ thu thập dữ liệu đa nguồn 11
CHƯƠNG 3. LÀM SẠCH VÀ CHUẨN HÓA DỮ LIỆU 13
3.1. Các vấn đề tiềm ẩn trong dữ liệu thô 13
3.2. Chương trình hỗ trợ quy trình xử lý 13
3.3. Kiểm chứng kết quả làm sạch 14
CHƯƠNG 4. TRỰC QUAN HÓA DỮ LIỆU 16
4.1. Danh sách thống kê cần thiết 16
4.2. Danh sách min – max 16
4.3. Các loại biểu đồ 16
CHƯƠNG 5. XÂY DỰNG MÔ HÌNH HỌC MÁY 18
5.1. Bốn bài toán 18
5.2. Đặc trưng đầu vào 18
5.3. Cách chia dữ liệu và chọn mô hình 18
5.4. Kết quả 19
5.5. Nhận xét về kết quả mô hình 20
CHƯƠNG 6. XÂY DỰNG HỆ THỐNG WEBSITE 21
6.1. Danh sách màn hình 21
6.2. Đăng nhập và phân quyền 21
6.3. Tìm kiếm, lọc và CRUD 22
6.4. Kết xuất báo cáo 22
6.5. Sao lưu và phục hồi dữ liệu 22
6.6. Thu thập dữ liệu từ website 23

CHƯƠNG 7. KIỂM THỬ HỆ THỐNG 24
7.1. Kiểm thử tự động phía backend 24
7.2. Kiểm thử giao diện 24
7.3. Kiểm thử trên máy khác 25
CHƯƠNG 8. NHẬN ĐỊNH VỀ DỮ LIỆU 26
8.1. Về mặt bằng giá và cơ cấu thị trường 26
8.2. Về khuyến mãi 26
8.3. Về thương hiệu 26
8.4. Về đánh giá của khách hàng 27
8.5. Về chất lượng dữ liệu 27
CHƯƠNG 9. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 29
9.1. Kết quả đạt được 29
9.2. Hạn chế 29
9.3. Hướng phát triển 30
TÀI LIỆU THAM KHẢO 31
PHỤ LỤC A. HƯỚNG DẪN CÀI ĐẶT VÀ CHẠY 32
PHỤ LỤC B. CẤU TRÚC THƯ MỤC 32

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI

1.1. Bối cảnh và lý do chọn đề tài

Thị trường mỹ phẩm bán lẻ trực tuyến tại Việt Nam có nhiều nhà bán lẻ lớn cùng phân phối những sản phẩm giống hoặc tương tự nhau. Cùng một sản phẩm có thể chênh lệch giá đáng kể giữa các website, và mức khuyến mãi thay đổi liên tục theo chiến dịch của từng bên. Người tiêu dùng khó so sánh thủ công, còn doanh nghiệp thì thiếu một bức tranh tổng hợp để định giá và theo dõi đối thủ.

Dữ liệu giá mỹ phẩm là dữ liệu thực tế, cập nhật thường xuyên, có cấu trúc rõ ràng (sản phẩm, giá, khuyến mãi, đánh giá) và có thể thu thập hợp lệ từ các kênh công khai. Đây là nguồn dữ liệu phù hợp để thực hành trọn vẹn quy trình phân tích dữ liệu lớn trong kinh doanh: từ thu thập, làm sạch, lưu trữ, trực quan hóa cho tới xây dựng mô hình học máy và đưa kết quả lên một hệ thống web hoàn chỉnh.

1.2. Mục tiêu đề tài

Nhóm xây dựng hệ thống BeautyPrice Intelligence với các mục tiêu sau:

- Thu thập và tổng hợp dữ liệu giá mỹ phẩm từ 5 nhà bán lẻ trực tuyến vào một cơ sở dữ liệu thống nhất.
- Phân tích, làm sạch và chuẩn hóa dữ liệu; ghi lại toàn bộ quy trình xử lý để có thể kiểm chứng.
- Trực quan hóa dữ liệu bằng dashboard và báo cáo thống kê, kèm danh sách min – max theo nhiều chiều.
- Áp dụng mô hình học có giám sát để dự đoán giá và phân loại phân khúc giá; mô hình học không giám sát để phân cụm sản phẩm và phát hiện điểm bất thường.
- Xây dựng website tích hợp toàn bộ chức năng, có đăng nhập và phân quyền, tìm kiếm – lọc, CRUD, kết xuất báo cáo ra tập tin, sao lưu và phục hồi dữ liệu.
- Xây dựng công cụ thu thập dữ liệu từ đa nguồn, hoạt động được cả bằng dòng lệnh lẫn trực tiếp trên website.

1.3. Phạm vi và giới hạn

Nội dung	Phạm vi thực hiện
Nhà bán lẻ	5 website: Hasaki, Watsons, Guardian, Cocolux, Thế Giới Skin Food
Danh mục sản phẩm	6 danh mục chăm sóc da và cơ thể: Sữa rửa mặt, Serum, Kem chống nắng, Tẩy trang, Sữa tắm, Tẩy tế bào chết
Quy mô dữ liệu	5.657 sản phẩm · 6.350 bản ghi giá · 6.673 đánh giá của khách hàng · 418 thương hiệu
Thời gian thu thập	18/10/2026 – 21/10/2026 (dữ liệu gốc); công cụ thu thập cho phép cập nhật định kỳ sau đó
Giới hạn	Guardian và Watsons bật cơ chế chống bot nên không thu thập tự động được ở các lần chạy sau; nhóm tôn trọng robots.txt và không vượt rào. Dữ liệu hai nguồn này là bản thu thập ban đầu

1.4. Công nghệ sử dụng

Thành phần	Công nghệ
Ngôn ngữ	Python 3.9+ (backend, thu thập, xử lý dữ liệu, học máy); HTML/CSS/JavaScript thuần (giao diện)
Cơ sở dữ liệu	SQLite 3 — toàn bộ CSDL là một tệp dataset/beautyprice.db
Backend / API	Flask, flask-cors; xác thực bằng token, mật khẩu băm PBKDF2-SHA256
Học máy	scikit-learn, pandas, numpy, joblib
Trực quan hóa	Chart.js 4.4.1 (lưu cục bộ, chạy được khi không có mạng)
Thu thập dữ liệu	Chỉ dùng thư viện chuẩn của Python (urllib, json, re, gzip…)
Kiểm thử	unittest (backend) và Puppeteer + Chrome headless (giao diện)
Quản lý mã nguồn	Git và GitHub

1.5. Kiến trúc tổng thể

Hệ thống gồm 4 tầng, nối với nhau qua một cơ sở dữ liệu SQLite duy nhất:

[1] Tầng thu thập: công cụ crawl.py lấy dữ liệu từ API hoặc HTML công khai của các website, lưu dữ liệu thô để truy vết rồi nạp vào CSDL.

[2] Tầng làm sạch và lưu trữ: build_database.py đọc dữ liệu gốc dạng CSV, làm sạch, chuẩn hóa và nạp vào CSDL; verify_database.py kiểm tra lại kết quả một cách độc lập.

[3] Tầng phân tích và học máy: train_models.py huấn luyện 4 nhóm mô hình và ghi kết quả trở lại CSDL.

[4] Tầng ứng dụng: backend Flask cung cấp API và phục vụ giao diện web gồm 9 màn hình.

Sơ đồ luồng dữ liệu chi tiết xem tại reports/THIET_KE_CSDL.md, mục 5.

CHƯƠNG 2. THU THẬP DỮ LIỆU VÀ THIẾT KẾ CƠ SỞ DỮ LIỆU

2.1. Phân tích đối tượng dữ liệu

Nhóm xác định các đối tượng chính cần quản lý và mối quan hệ giữa chúng như sau:

Đối tượng	Thuộc tính chính	Quan hệ
Nhà bán lẻ (retailers)	Mã, tên, quốc gia, đơn vị tiền, website	1 nhà bán lẻ có nhiều sản phẩm
Danh mục (categories)	Mã, tên danh mục	1 danh mục gồm nhiều sản phẩm; 1 sản phẩm có thể thuộc nhiều danh mục
Sản phẩm (products)	Mã, tên, thương hiệu, nhà bán lẻ, danh mục chính, liên kết, dung tích, khối lượng, số món, cờ combo	Có nhiều bản ghi giá và nhiều đánh giá
Bản ghi giá (price_snapshots)	Mã, sản phẩm, giá bán, giá niêm yết, % giảm, rating, số lượt đánh giá, thời điểm thu thập	Thuộc về 1 sản phẩm; mỗi lần thu thập sinh một bản ghi mới
Đánh giá (reviews)	Nguồn, mã đánh giá, sản phẩm, số sao, nội dung, ngày, đã mua, có ảnh, tên người đánh giá rút gọn	Thuộc về 1 sản phẩm; có thể dùng chung giữa các biến thể
Người dùng (users)	Tên đăng nhập, mật khẩu băm, vai trò	Phân quyền Admin / User

2.2. Quy tắc nghiệp vụ

Các quy tắc nghiệp vụ được cài đặt trực tiếp bằng ràng buộc trong CSDL, nên dữ liệu sai không thể lọt vào bảng:

- Giá bán phải lớn hơn 0.
- Giá niêm yết nếu có phải lớn hơn hoặc bằng giá bán; nếu nhỏ hơn thì coi là dữ liệu sai và bỏ đi.
- Phần trăm giảm giá được tính lại theo công thức (giá niêm yết − giá bán) / giá niêm yết × 100, không lấy số có sẵn trên website.
- Rating nằm trong khoảng 0–5; rating bằng 0 nghĩa là chưa có đánh giá nên được ghi là NULL, không coi là 0 sao.

- Số sao của đánh giá nằm trong khoảng 1–5 và giữ nguyên nửa sao (Guardian có các mức 4,5 và 3,5).
- Liên kết sản phẩm chỉ chấp nhận dạng http hoặc https.
- Một đánh giá là duy nhất theo bộ ba (nguồn, mã sản phẩm ở nguồn, mã đánh giá).
- Sửa giá trên website không ghi đè giá cũ mà thêm một bản ghi giá mới, nhờ vậy lịch sử giá được giữ nguyên.

2.3. Lựa chọn hệ quản trị cơ sở dữ liệu

Nhóm chọn SQLite sau khi cân nhắc giữa các hệ quản trị phổ biến. Lý do:

Tiêu chí	Đánh giá
Cài đặt	Không cần cài máy chủ CSDL. Python có sẵn module sqlite3 nên chạy được ngay trên máy chấm bài.
Tính di động	Toàn bộ CSDL là một tệp khoảng 9,3 MB. Chép thư mục dự án sang máy khác là chạy được.
Phù hợp quy mô	Khoảng 5,7 nghìn sản phẩm và hơn 19 nghìn bản ghi; số người dùng ghi đồng thời nhỏ.
Tính năng quan hệ	Đầy đủ khóa chính, khóa ngoại, ràng buộc CHECK và UNIQUE, chỉ mục, view, hàm cửa sổ ROW_NUMBER, giao dịch.
Khả năng chuyển đổi	Lược đồ viết bằng SQL chuẩn nên chuyển sang MySQL hoặc PostgreSQL chỉ cần sửa phần kiểu tự tăng và chuỗi kết nối.

Để minh họa khả năng chuyển sang CSDL phi quan hệ, tệp queries.sql ghi kèm câu lệnh MongoDB tương đương cho từng truy vấn mẫu.

2.4. Lược đồ cơ sở dữ liệu

Lược đồ gồm 17 bảng và 2 view, chia thành 4 nhóm:

Nhóm	Bảng
Danh mục nền	retailers, categories
Dữ liệu nghiệp vụ	products, product_categories, price_snapshots, reviews, review_links, product_matching
Vận hành hệ thống	users, app_settings, collection_logs, etl_log
Kết quả học máy	ml_runs, ml_price_predictions, ml_clusters, ml_anomalies, ml_feature_importance

Hai view giúp truy vấn gọn hơn: v_latest_snapshot lấy bản ghi giá mới nhất của mỗi sản phẩm bằng hàm cửa sổ ROW_NUMBER, còn v_products ghép sản phẩm với tên nhà bán lẻ, danh mục và giá mới nhất. Hầu hết màn hình của website đọc trực tiếp từ v_products.

Sơ đồ quan hệ (ERD) và từ điển dữ liệu đầy đủ xem tại reports/THIET_KE_CSDL.md.

2.5. Công cụ thu thập dữ liệu đa nguồn

Nhóm xây dựng công cụ thu thập riêng (source-code/crawler/crawl.py), chỉ dùng thư viện chuẩn của Python. Công cụ chạy được bằng dòng lệnh và cũng được gọi trực tiếp từ trang quản trị trên website.

Nguồn	Cách lấy dữ liệu	Kết quả
Hasaki	API JSON công khai mà chính website sử dụng	Lấy được giá và đánh giá
Cocolux	API JSON danh sách sản phẩm	Lấy được giá và đánh giá
Thế Giới Skin Food	API JSON của nền tảng Haravan	Lấy được giá
Guardian	Phân tích HTML trang danh mục	Lấy được giá ở đợt đầu; sau đó website bật Cloudflare nên bị chặn
Watsons	Kiểm tra truy cập	Bị chặn bởi Akamai, hệ thống ghi nhận trạng thái blocked

Nguyên tắc thu thập mà nhóm tuân thủ:

- Đọc và tuân thủ tệp robots.txt của từng website; đường dẫn bị cấm thì không gửi yêu cầu.
- Giãn cách giữa hai yêu cầu tới cùng một website, mặc định 1,5 giây và không cho đặt dưới 1 giây.
- Khai báo User-Agent ghi rõ đây là công cụ của đồ án sinh viên.
- Khi website trả về mã chặn hoặc trang kiểm tra chống bot, công cụ chỉ ghi nhận trạng thái blocked và dừng, không tìm cách vượt qua.
- Tên người đánh giá chỉ lưu ở dạng rút gọn, ví dụ "Nguyễn Văn An" thành "Nguyễn V. A."; không lưu mã tài khoản, email hay số điện thoại.

- Lưu lại toàn bộ dữ liệu thô dạng nén để có thể truy vết và dựng lại CSDL mà không cần gọi lại website.

Mã sản phẩm được sinh bằng công thức băm SHA-256 từ cặp (nhà bán lẻ, liên kết sản phẩm), trùng với công thức của bộ dữ liệu gốc. Nhờ vậy, mỗi lần thu thập mới hệ thống tự nhận ra sản phẩm đã có và nối tiếp lịch sử giá thay vì tạo sản phẩm trùng.

CHƯƠNG 3. LÀM SẠCH VÀ CHUẨN HÓA DỮ LIỆU

3.1. Các vấn đề tiềm ẩn trong dữ liệu thô

Sau khi khảo sát bộ dữ liệu thu thập được, nhóm xác định các vấn đề sau:

Vấn đề	Mô tả
Tên sản phẩm không đồng nhất	Chứa ký tự vô hình (zero-width), khoảng trắng thừa, biểu diễn Unicode khác nhau cho cùng một chữ
Thương hiệu viết nhiều kiểu	"L'Oréal", "L'Oreal", "LOREAL"; "La Roche-Posay" và "LA ROCHE POSAY" được hiểu là các thương hiệu khác nhau
Giá không hợp lệ	Giá bằng 0 hoặc không đọc được; giá niêm yết nhỏ hơn giá bán
Phần trăm giảm giá sai lệch	Số % ghi trên website không khớp với hiệu hai mức giá
Nhầm lẫn giá trị thiếu với giá trị 0	Rating bằng 0 thực chất là "chưa có đánh giá", nếu tính trung bình sẽ kéo điểm xuống
Bản ghi trùng	Cùng một sản phẩm xuất hiện ở nhiều danh mục nên bị ghi lại nhiều lần
Định dạng ngày khác nhau	Hasaki dùng "2025-09-27 17:17:59", Guardian dùng "22 tháng 4, 2025"
Đánh giá nửa sao bị cắt	Giá trị 4,5 bị ép về số nguyên 4 làm sai điểm trung bình

3.2. Chương trình hỗ trợ quy trình xử lý

Nhóm viết chương trình build_database.py (chỉ dùng thư viện chuẩn Python) thực hiện toàn bộ quy trình làm sạch và nạp dữ liệu. Điểm quan trọng là mỗi bước xử lý đều ghi một dòng vào bảng etl_log, gồm tên bước, bảng tác động, số dòng vào, số dòng ra và số dòng bị thay đổi. Nhờ vậy quy trình làm sạch không phải là hộp đen mà có thể xem lại ngay trên trang Báo cáo của website.

Kết quả một số bước làm sạch chính trên bộ dữ liệu hiện tại:

Bước xử lý	Tác động
Chuẩn hóa Unicode, bỏ ký tự vô hình, gộp khoảng trắng trong tên	43 sản phẩm
Gộp các cách viết khác nhau của cùng một thương hiệu	1.611 sản phẩm, còn lại 418 thương hiệu
Danh mục không hợp lệ hoặc để trống thì ghi NULL	569 sản phẩm

Bước xử lý	Tác động
Trích dung tích, khối lượng, số món và cờ combo từ tên sản phẩm	5.304 sản phẩm có dung tích hoặc khối lượng
Tính lại phần trăm giảm giá từ hai mức giá	4.861 bản ghi; 114 dòng lệch so với số trên website trên 1 điểm phần trăm
Không đủ cặp giá thì để phần trăm giảm là NULL thay vì ghi 0	1.489 bản ghi
Rating bằng 0 được ghi NULL vì là "chưa có đánh giá"	864 bản ghi
Chuẩn hóa ngày đánh giá về định dạng ISO 8601	6.673 đánh giá
Nối đánh giá với sản phẩm theo mã ở nguồn	6.588 trên 6.673 đánh giá

Riêng việc nối đánh giá với sản phẩm là một cải tiến đáng kể. Cách làm ban đầu là so khớp theo tên gần đúng, dẫn tới gắn nhầm đánh giá giữa các sản phẩm combo và sản phẩm lẻ. Nhóm chuyển sang nối theo mã sản phẩm của chính website nguồn: Hasaki dùng dãy số ở cuối liên kết, Guardian dùng liên kết đã chuẩn hóa. Kết quả khớp 6.178 trên 6.263 đánh giá Hasaki và toàn bộ 410 đánh giá Guardian.

3.3. Kiểm chứng kết quả làm sạch

Để chứng minh dữ liệu trong CSDL đúng chứ không chỉ "chạy không lỗi", nhóm viết thêm chương trình verify_database.py thực hiện kiểm tra độc lập: đọc thẳng các tệp CSV gốc bằng Python thuần, tự tính lại số bản ghi từng bảng và kết quả của 7 truy vấn mẫu, rồi so sánh với kết quả truy vấn SQL trên CSDL.

- So sánh số dòng của từng bảng giữa CSV và CSDL.
- Kiểm tra toàn vẹn CSDL bằng PRAGMA integrity_check và kiểm tra khóa ngoại bằng PRAGMA foreign_key_check.
- Đối chiếu kết quả 6 truy vấn (truy vấn thứ 7 chỉ mang tính minh họa).
- Kết luận được ghi ra tệp reports/KIEM_TRA_CSDL.md; nếu có mục nào sai, chương trình thoát với mã lỗi.

Kết quả hiện tại: tất cả các mục đều đạt. Nhóm cũng đã thử cố ý sửa dữ liệu trong CSDL (xóa một dòng, đổi một mức giá) và chương trình kiểm tra phát hiện đúng chỗ sai.

CHƯƠNG 4. TRỰC QUAN HÓA DỮ LIỆU

4.1. Danh sách thống kê cần thiết

Nhóm xác định các nhóm chỉ số cần theo dõi và thể hiện trên dashboard:

Nhóm chỉ số	Nội dung
Chỉ số tổng quan	Tổng số sản phẩm, số thương hiệu, giá trung vị, số sản phẩm đang giảm giá
Cơ cấu thị trường	Tỷ trọng sản phẩm theo nhà bán lẻ, phân bố theo khoảng giá, giá trung vị theo danh mục
Khuyến mãi	Phân bố mức giảm giá theo nhà bán lẻ, tỷ lệ sản phẩm đang giảm giá
Thương hiệu	Top thương hiệu theo số sản phẩm, giá trung vị và mức giảm của từng thương hiệu
Biến động giá	Giá trung vị theo ngày thu thập, lịch sử giá của từng sản phẩm
Đánh giá khách hàng	Số đánh giá và điểm trung bình theo nguồn, phân bố số sao, tỷ lệ đã mua hàng và có ảnh
Chất lượng dữ liệu	Tỷ lệ thiếu dữ liệu từng trường, các bước làm sạch đã thực hiện

4.2. Danh sách min – max

Trang Báo cáo thống kê có riêng một mục liệt kê giá trị nhỏ nhất và lớn nhất theo ba chiều: theo danh mục, theo nhà bán lẻ và theo từng chỉ số. Mỗi dòng ghi kèm tên sản phẩm đạt giá trị đó để có thể kiểm chứng. Một số số liệu nổi bật:

Nhà bán lẻ	Số SP	Giá TB	Thấp nhất	Cao nhất
Hasaki	1.767	287.215 đ	9.000 đ	2.625.000 đ
Watsons	1.683	313.358 đ	17.000 đ	2.963.000 đ
Guardian	984	321.794 đ	31.000 đ	3.160.000 đ
Cocolux	724	385.823 đ	5.000 đ	3.160.000 đ
Thế Giới Skin Food	499	279.283 đ	24.000 đ	1.409.000 đ

Khi một chỉ số bị thiếu dữ liệu, hệ thống hiển thị dấu gạch ngang thay vì số 0, để người đọc không nhầm giữa "bằng 0" và "chưa có dữ liệu".

4.3. Các loại biểu đồ

Nhóm sử dụng nhiều dạng biểu đồ khác nhau, mỗi dạng phù hợp với một loại thông tin:

Loại biểu đồ	Dùng ở trang	Thể hiện nội dung
Biểu đồ vành khuyên	Tổng quan, Báo cáo	Tỷ trọng sản phẩm theo nhà bán lẻ, cơ cấu mức giảm giá
Biểu đồ cột	Tổng quan, Phân khúc, Dự đoán	Phân bố theo khoảng giá, số sản phẩm theo cụm, so sánh các mô hình
Biểu đồ cột ngang	Tổng quan, Dự đoán	Giá trung vị theo danh mục, độ quan trọng của đặc trưng
Biểu đồ cột chồng 100%	Tổng quan, Phân khúc	Cơ cấu mức giảm giá và cơ cấu nhà bán lẻ trong từng cụm
Biểu đồ đường	Tổng quan, Tra cứu, Phân khúc	Giá trung vị theo ngày, lịch sử giá sản phẩm, chỉ số silhouette theo k
Biểu đồ phân tán	Dự đoán, Bất thường	Giá thực tế so với giá dự đoán, phân bố điểm bất thường
Biểu đồ bong bóng	Phân khúc	Giá và mức giảm của từng cụm, kích thước thể hiện số sản phẩm
Ma trận nhầm lẫn	Dự đoán	Kết quả phân loại phân khúc giá trên tập kiểm tra

Về mặt trình bày, toàn bộ biểu đồ dùng chung một bảng màu đã được kiểm tra khả năng phân biệt cho người mù màu. Màu được gán cố định theo thực thể (mỗi nhà bán lẻ, mỗi phân khúc, mỗi cụm một màu), nên khi lọc dữ liệu thì màu của các nhóm còn lại không bị đổi. Mỗi biểu đồ đều có chú giải, nhãn trục và ghi chú giải thích cách đọc.

CHƯƠNG 5. XÂY DỰNG MÔ HÌNH HỌC MÁY

5.1. Bốn bài toán

Bài toán	Loại	Câu hỏi kinh doanh
Dự đoán giá bán	Học có giám sát, hồi quy	Một sản phẩm với các thuộc tính như vậy thì giá hợp lý khoảng bao nhiêu?
Phân loại phân khúc giá	Học có giám sát, phân loại 3 lớp	Sản phẩm này thuộc phân khúc Thấp, Trung bình hay Cao?
Phân cụm sản phẩm	Học không giám sát	Thị trường chia thành những nhóm sản phẩm nào?
Phát hiện bất thường	Học không giám sát	Sản phẩm nào có giá hoặc mức giảm khác thường, cần rà soát?

5.2. Đặc trưng đầu vào

Bộ đặc trưng dùng chung cho hai bài toán học có giám sát gồm 4 biến phân loại (thương hiệu, danh mục, loại sản phẩm, nhà bán lẻ) và 7 biến số (số danh mục, rating, logarit số lượt đánh giá, logarit dung tích, logarit khối lượng, số món, cờ combo).

Hai lưu ý quan trọng về mặt phương pháp:

- Nhóm không đưa giá niêm yết và phần trăm giảm giá vào đặc trưng, vì hai giá trị này suy ra trực tiếp từ giá bán. Nếu dùng, mô hình sẽ đạt kết quả rất cao nhưng đó là rò rỉ mục tiêu chứ không phải năng lực dự đoán thật.
- Mô hình hồi quy học trên logarit của giá vì phân bố giá lệch phải mạnh (trung vị 240.000 đồng nhưng giá cao nhất tới 3,16 triệu). Kết quả được đổi ngược về đồng Việt Nam trước khi tính sai số. Nhóm đã thử học thẳng trên giá gốc và kết quả kém hơn ở mọi chỉ số.

5.3. Cách chia dữ liệu và chọn mô hình

Dữ liệu được chia thành ba phần theo tỷ lệ 60 / 20 / 20 (3.393 / 1.132 / 1.132 sản phẩm) với random_state cố định bằng 42 để kết quả lặp lại được. Quy trình chọn mô hình:

[1] Huấn luyện tất cả các mô hình ứng viên trên tập train.

[2] So sánh chúng trên tập validation và chọn mô hình tốt nhất.

[3] Huấn luyện lại mô hình được chọn trên train cộng validation.

[4] Báo cáo kết quả một lần duy nhất trên tập test.

Ngưỡng phân khúc giá cũng được tính trên tập train rồi mới áp cho validation và test, nhằm tránh rò rỉ thông tin. Mỗi bài toán đều có một mô hình Dummy làm mốc so sánh; mô hình thật phải vượt rõ rệt mốc này mới được coi là có giá trị.

5.4. Kết quả

Bài toán hồi quy giá, so sánh trên tập validation:

Mô hình	MAE (đ)	RMSE (đ)	R^2	MAPE
Dummy (trung vị) — mốc	171.288	289.568	−0,057	87,9%
Ridge Regression	109.613	198.900	0,501	47,4%
Random Forest (được chọn)	94.089	177.891	0,601	39,2%
Extra Trees	99.220	192.800	0,531	45,0%

Random Forest trên tập test đạt MAE 90.290 đồng, RMSE 168.259 đồng, R^2 0,536 và MAPE 35,2%. So với mốc Dummy, sai số tuyệt đối trung bình giảm khoảng 45%.

Bài toán phân loại phân khúc giá, so sánh trên tập validation:

Mô hình	Accuracy	Precision	Recall	F1-macro
Dummy (lớp phổ biến) — mốc	0,346	0,115	0,333	0,172
Logistic Regression	0,672	0,667	0,673	0,667
Random Forest	0,695	0,690	0,696	0,690
Extra Trees (được chọn)	0,704	0,701	0,705	0,700

Extra Trees trên tập test đạt accuracy 73,5% và F1-macro 0,732. Phân tích ma trận nhầm lẫn cho thấy lỗi chủ yếu xảy ra giữa hai nhóm liền kề; chỉ có 34 trên 1.132 trường hợp nhầm lẫn giữa Thấp và Cao. Nhóm Trung bình khó phân loại nhất vì nằm giữa hai ngưỡng.

Bài toán phân cụm: thử k từ 2 đến 10 và chọn theo chỉ số silhouette. Giá trị k = 7 cho silhouette cao nhất là 0,285. Bài toán phát hiện bất thường: Isolation Forest với tham số contamination 5% đánh dấu 283 trên 5.657 sản phẩm, mỗi sản phẩm kèm lý do cụ thể.

5.5. Nhận xét về kết quả mô hình

- Thương hiệu là yếu tố quyết định giá, chiếm 38% độ quan trọng ở mô hình hồi quy và 46% ở mô hình phân loại; tiếp theo là dung tích và danh mục.
- Rating và số lượt đánh giá gần như không giúp dự đoán giá (dưới 3%). Sản phẩm được đánh giá cao không đồng nghĩa với giá đắt hay rẻ.
- Hàng giá rẻ khó dự đoán theo tỷ lệ phần trăm (sai số 55,8%), vì chênh lệch 50 nghìn trên sản phẩm 80 nghìn đã là hơn 60%. Nhóm trung bình và cao chính xác hơn nhiều, khoảng 23–27%.
- Hệ số R^2 khoảng 0,54 nghĩa là mô hình giải thích được khoảng một nửa biến động giá. Phần còn lại đến từ những yếu tố không có trong dữ liệu như thành phần, xuất xứ, kênh phân phối.
- Chỉ số silhouette khoảng 0,28 cho thấy các cụm có chồng lấn; thị trường mỹ phẩm không chia thành những nhóm tách bạch. Kết quả phân cụm nên dùng để mô tả xu hướng, không nên coi là ranh giới cứng.

CHƯƠNG 6. XÂY DỰNG HỆ THỐNG WEBSITE

6.1. Danh sách màn hình

Màn hình	Chức năng chính
Đăng nhập	Đăng nhập, hiển thị số liệu tổng lấy trực tiếp từ CSDL, nút điền nhanh tài khoản demo
Tổng quan	4 chỉ số chính, bộ lọc nhiều tiêu chí, 6 biểu đồ, nhận định tự động
Tra cứu dữ liệu	Tìm kiếm không dấu, lọc, sắp xếp, phân trang, CRUD sản phẩm, lịch sử giá, đánh giá, xuất CSV
Phân khúc (K-Means)	Chọn k theo silhouette, đặc điểm từng cụm, danh sách sản phẩm theo cụm
Dự đoán giá	So sánh các mô hình, độ quan trọng đặc trưng, ma trận nhầm lẫn, bảng dự đoán
Phát hiện bất thường	Danh sách sản phẩm cần rà soát kèm lý do, độ nhạy theo tham số
Báo cáo thống kê	Thống kê mô tả, danh sách min – max, phân bố, đánh giá, chất lượng dữ liệu, in PDF, xuất CSV
Thu thập dữ liệu (Admin)	Gọi công cụ thu thập, chạy nền có nhật ký và nút dừng, lịch tự động, lịch sử thu thập
Sao lưu và phục hồi (Admin)	Tạo bản sao lưu, tải về, tải lên, phục hồi kèm bảng kiểm tra sau phục hồi

6.2. Đăng nhập và phân quyền

Hệ thống có hai vai trò: Quản trị viên và Người dùng. Khi đăng nhập thành công, server cấp một token ngẫu nhiên có hạn 8 giờ; mọi yêu cầu sau đó phải gửi kèm token này.

Chức năng	Người dùng	Quản trị viên
Xem toàn bộ màn hình phân tích, tìm kiếm, lọc	Có	Có
Xuất CSV, in hoặc lưu PDF	Có	Có
Thêm, sửa, xóa sản phẩm	Không	Có
Thu thập dữ liệu, đặt lịch tự động	Không	Có
Sao lưu, tải lên, phục hồi dữ liệu	Không	Có

Phân quyền được kiểm tra ở cả hai phía. Giao diện ẩn nút và mục menu không thuộc quyền, còn backend kiểm tra lại vai trò ở từng API và trả về mã 401 nếu chưa đăng nhập,

mã 403 nếu sai quyền. Nhóm đã thử sửa vai trò trong trình duyệt và hệ thống vẫn trả về đúng vai trò thật từ server.

Về an toàn, mật khẩu chỉ được lưu dưới dạng băm PBKDF2-SHA256 có muối, không lưu mật khẩu gốc. Nếu đăng nhập sai 5 lần, hệ thống khóa địa chỉ đó trong 5 phút để chống dò mật khẩu.

6.3. Tìm kiếm, lọc và CRUD

Trang Tra cứu hỗ trợ tìm kiếm không phân biệt dấu, nên gõ "sua rua mat" vẫn ra "Sữa rửa mặt". Người dùng có thể lọc đồng thời theo nhà bán lẻ, danh mục, thương hiệu, khoảng giá và mức giảm giá, kết hợp với sắp xếp và phân trang.

Chức năng CRUD dành cho quản trị viên có một điểm đáng chú ý về mặt nghiệp vụ: khi sửa giá, hệ thống không ghi đè bản ghi cũ mà thêm một bản ghi giá mới. Nhờ vậy lịch sử giá được giữ nguyên và biểu đồ lịch sử giá của sản phẩm phản ánh đúng diễn biến. Mọi dữ liệu nhập vào đều được kiểm tra ở backend trước khi lưu.

6.4. Kết xuất báo cáo

Hệ thống cho phép xuất dữ liệu ra tệp ở bốn màn hình: Tra cứu (danh sách đang lọc), Dự đoán giá, Phát hiện bất thường và Báo cáo thống kê. Tệp CSV được ghi kèm dấu BOM để Excel mở đúng tiếng Việt, và các ô bắt đầu bằng ký tự công thức được thêm dấu nháy để tránh bị Excel thực thi. Riêng trang Báo cáo còn có chức năng in hoặc lưu thành PDF với bố cục riêng cho bản in.

6.5. Sao lưu và phục hồi dữ liệu

Đây là chức năng được nhóm đầu tư kỹ vì liên quan trực tiếp tới an toàn dữ liệu. Quy trình gồm bốn bước:

Bước	Nội dung
Sao lưu	Dùng SQLite Online Backup API nên an toàn ngay cả khi website đang chạy. Ngay sau khi tạo, hệ thống kiểm tra toàn vẹn, đếm số dòng 13 bảng và tính mã băm SHA-256
Trước khi phục hồi	Đối chiếu mã băm để phát hiện tệp bị sửa, kiểm tra toàn vẹn bản sao lưu, và tự tạo một bản an toàn từ dữ liệu hiện tại
Phục hồi	Ghi bản sao lưu vào CSDL đang chạy, sau đó bổ sung các bảng hoặc cột mới nếu đó là bản sao lưu cũ

Bước	Nội dung
Sau khi phục hồi	Kiểm tra lại toàn vẹn, khóa ngoại và so sánh số dòng của 13 bảng với bản sao lưu, rồi hiển thị bảng kết quả Khớp hoặc Lệch

Hệ thống còn cho phép tải lên tệp cơ sở dữ liệu từ máy khác để phục hồi. Tệp tải lên phải vượt qua các kiểm tra: đúng định dạng SQLite, đủ bảng và cột của hệ thống, không chứa view hoặc trigger lạ, có ít nhất một tài khoản quản trị, và qua được kiểm tra toàn vẹn.

6.6. Thu thập dữ liệu từ website

Trang Thu thập dữ liệu cho phép quản trị viên gọi công cụ thu thập ngay trên giao diện mà không cần dùng dòng lệnh. Người dùng chọn nguồn, danh mục và tự nhập lượng dữ liệu muốn lấy; hệ thống hiển thị ước tính số yêu cầu và thời gian trước khi chạy. Công việc chạy nền trong một luồng riêng, nhật ký cập nhật mỗi 2 giây và có nút dừng. Ngoài ra có thể đặt lịch tự động theo chu kỳ giờ hoặc ngày kèm giờ chạy lần đầu.

CHƯƠNG 7. KIỂM THỬ HỆ THỐNG

7.1. Kiểm thử tự động phía backend

Tệp kiểm thử	Nội dung kiểm tra	Kết quả
test_api.py	Đăng nhập và phân quyền, các API đọc dữ liệu, kiểm tra dữ liệu đầu vào, CRUD giữ lịch sử giá, đánh giá theo sản phẩm, tùy chọn và lịch thu thập	6/6 đạt
test_backup.py	Sao lưu rồi thay đổi dữ liệu rồi phục hồi và đối chiếu độc lập, từ chối bản sao lưu bị sửa, tải lên tệp hợp lệ và 7 loại tệp không hợp lệ	7/7 đạt
test_crawler.py	Công thức mã sản phẩm, luật robots.txt, bộ phân tích HTML, các bước làm sạch, nạp đánh giá và nối đánh giá dùng chung	8/8 đạt

Toàn bộ kiểm thử chạy trên bản sao của cơ sở dữ liệu nên không làm thay đổi dữ liệu thật.

7.2. Kiểm thử giao diện

Nhóm viết 21 test case chạy tự động trên trình duyệt Chrome bằng Puppeteer. Kịch bản thao tác đúng như người dùng thật rồi đối chiếu kết quả hiển thị với dữ liệu trong CSDL, đồng thời tự chụp ảnh từng bước và quay lại toàn bộ lượt chạy.

Nhóm test case	Nội dung	Số lượng
Đăng nhập và phân quyền	Chưa đăng nhập bị chuyển hướng, sai mật khẩu, đăng nhập đúng, người dùng thường bị chặn, đăng xuất	6
Dashboard và mô hình	Lọc theo nhà bán lẻ, ba trang kết quả mô hình hiển thị đủ và không có giá trị lỗi	4
Tra cứu và CRUD	Tìm kiếm không dấu, xem chi tiết và lịch sử giá, thêm sai dữ liệu, thêm đúng, sửa giá, xóa	6
Kết xuất báo cáo	Xuất CSV ở trang Tra cứu, xuất CSV và PDF ở trang Báo cáo	2
Sao lưu và phục hồi	Tạo bản sao lưu, phục hồi thực tế sau khi dữ liệu bị thay đổi	2
Giao diện	Hiển thị trên màn hình điện thoại 390 pixel	1

Kết quả: 21 trên 21 test case đạt, không có lỗi JavaScript nào. Toàn bộ ảnh chụp, video và tệp xuất được lưu trong thư mục reports/demo để làm bằng chứng.

7.3. Kiểm thử trên máy khác

Nhóm đã thử chạy dự án trên một bản sao không có sẵn cơ sở dữ liệu. Tệp run.bat tự tạo môi trường ảo, cài thư viện và backend tự dựng CSDL từ dữ liệu gốc. Khi chưa huấn luyện mô hình, các trang liên quan hiển thị thông báo chưa có kết quả chứ không báo lỗi.

CHƯƠNG 8. NHẬN ĐỊNH VỀ DỮ LIỆU

Phần này trình bày các nhận định của nhóm rút ra từ dữ liệu thực tế đã thu thập.

8.1. Về mặt bằng giá và cơ cấu thị trường

- Giá mỹ phẩm phân bố lệch phải rõ rệt: giá trung vị là 240.000 đồng nhưng giá trung bình lên tới 312.928 đồng và sản phẩm đắt nhất là 3,16 triệu đồng. Vì vậy khi mô tả mặt bằng giá, nhóm dùng trung vị thay cho trung bình, bởi trung bình bị kéo lệch bởi nhóm sản phẩm cao cấp.
- Khoảng giá phổ biến nhất là 100 đến 300 nghìn đồng với 2.639 sản phẩm, chiếm 46,7% toàn bộ. Đây là phân khúc cạnh tranh gay gắt nhất.
- Giữa các nhà bán lẻ có sự phân hóa về định vị. Cocolux có giá trung bình cao nhất (385.823 đồng), trong khi Thế Giới Skin Food và Hasaki có mặt bằng giá thấp hơn (279.283 và 287.215 đồng). Chênh lệch giữa nơi cao nhất và thấp nhất lên tới 38%.
- Theo danh mục, Serum có giá trung bình cao nhất (490.678 đồng), gấp hơn hai lần so với Sữa tắm (222.483 đồng) và Tẩy tế bào chết (231.539 đồng). Điều này phù hợp với thực tế: serum là sản phẩm đặc trị, hàm lượng hoạt chất cao nên giá thành cao hơn.

8.2. Về khuyến mãi

- Giảm giá là trạng thái phổ biến chứ không phải ngoại lệ: 4.293 sản phẩm đang giảm giá, chiếm 75,9% toàn thị trường, với mức giảm trung vị 25%.
- Mức độ khuyến mãi khác nhau rõ rệt giữa các nhà bán lẻ. Hasaki khuyến mãi nhiều nhất với 97,2% sản phẩm đang giảm giá, trong khi Guardian chỉ có 52,2%.
- Tỷ lệ giảm giá cao và thường xuyên như vậy cho thấy giá niêm yết ở nhiều nơi mang tính tham chiếu nhiều hơn là giá bán thực tế. Khi phân tích, nhóm luôn dùng giá bán hiện tại làm cơ sở thay vì giá niêm yết.
- Mức giảm sâu bất thường (tối đa 98%) thường rơi vào hàng cận hạn sử dụng hoặc xả kho. Mô hình phát hiện bất thường đã đánh dấu nhóm này để rà soát.

8.3. Về thương hiệu

- Thị trường rất phân mảnh: có tới 418 thương hiệu, nhưng 8 thương hiệu dẫn đầu chỉ chiếm 21,5% số sản phẩm. Không có thương hiệu nào thực sự thống trị.
- Cocoon là thương hiệu có nhiều sản phẩm nhất với 301 sản phẩm, chiếm 5,3%. Tiếp theo là EUCERIN (172), Garnier (143), SUNPLAY (139) và La Roche-Posay (136).
- Thương hiệu là yếu tố quan trọng nhất quyết định giá, chiếm 38% độ quan trọng trong mô hình dự đoán giá. Điều này cho thấy người tiêu dùng trả tiền cho thương hiệu nhiều hơn là cho quy cách sản phẩm.

8.4. Về đánh giá của khách hàng

- Điểm đánh giá lệch rất mạnh về phía tích cực: 5.999 trên 6.673 đánh giá là 5 sao, chiếm 89,9%. Điểm trung bình là 4,90 với Hasaki và 4,93 với Guardian.
- Với phân bố như vậy, điểm đánh giá gần như không có khả năng phân biệt chất lượng giữa các sản phẩm. Đây là lý do mô hình học máy xếp rating và số lượt đánh giá vào nhóm đặc trưng ít giá trị nhất (dưới 3%).
- Dữ liệu đánh giá cũng thiếu nhiều: 65,5% sản phẩm chưa có rating. Nhóm giữ các giá trị này ở dạng NULL thay vì điền 0, để không làm sai lệch thống kê.
- Một lưu ý về độ tin cậy: toàn bộ 410 đánh giá của Guardian đều có trạng thái đã mua hàng. Nhiều khả năng đây là giá trị mặc định của nguồn chứ không phải thông tin thật, nên nhóm không dùng chỉ số này để kết luận.

8.5. Về chất lượng dữ liệu

- Việc một sản phẩm thuộc nhiều danh mục khiến số bản ghi (6.350) lớn hơn số sản phẩm thật (5.657). Nếu không xử lý, mọi thống kê sẽ bị đếm trùng 693 lần. Đây là bài học quan trọng khi làm việc với dữ liệu thu thập theo danh mục.
- Các website hiển thị cùng một đánh giá trên mọi biến thể của sản phẩm (khác dung tích, khác mùi). Nhóm giải quyết bằng cách lưu mỗi đánh giá một lần và dùng một bảng nối riêng để liên kết với các biến thể, nhờ vậy vừa không đếm trùng khi thống kê vừa hiển thị đủ khi tra cứu.

- Có 1.360 sản phẩm không có giá niêm yết nên không tính được phần trăm giảm giá. Nhóm để trống thay vì ghi 0, vì 0% nghĩa là có giá niêm yết nhưng không giảm, hoàn toàn khác với không có dữ liệu.
- Nhìn chung, phần lớn công sức của đồ án nằm ở khâu làm sạch và kiểm chứng dữ liệu chứ không phải ở khâu xây dựng mô hình. Dữ liệu sạch và có thể kiểm chứng mới là nền tảng để mọi phân tích phía sau đáng tin cậy.

CHƯƠNG 9. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

9.1. Kết quả đạt được

Yêu cầu của đề bài	Kết quả thực hiện	Trạng thái
Phân tích dữ liệu, thiết kế mô hình quan hệ	17 bảng, 2 view, đầy đủ ràng buộc và chỉ mục	Đạt
Chọn hệ quản trị cơ sở dữ liệu	SQLite 3	Đạt
Công cụ thu thập đa nguồn (điểm cộng)	5 nguồn, chạy được từ website, có lịch tự động	Đạt
Làm sạch và chuẩn hóa, có chương trình hỗ trợ	build_database.py, ghi nhật ký từng bước, có chương trình kiểm chứng độc lập	Đạt
Dashboard, danh sách min – max, biểu đồ đa dạng	9 màn hình, 8 loại biểu đồ, mục min – max riêng	Đạt
Mô hình học không giám sát	K-Means và Isolation Forest	Đạt
Mô hình học có giám sát	Hồi quy giá và phân loại phân khúc, mỗi bài toán so sánh 4 mô hình	Đạt
Website tích hợp, đăng nhập và phân quyền	9 màn hình, 2 vai trò, kiểm tra ở cả hai phía	Đạt
Tìm kiếm và lọc (điểm cộng)	Tìm không dấu, 5 bộ lọc kết hợp	Đạt
CRUD dữ liệu quan trọng (điểm cộng)	Thêm, sửa, xóa sản phẩm; sửa giá giữ lịch sử	Đạt
Kết xuất báo cáo ra tập tin (điểm cộng)	CSV ở 4 màn hình và in hoặc lưu PDF	Đạt

9.2. Hạn chế

[1] Dữ liệu gốc chỉ trải trên 4 ngày thu thập nên chưa đủ để phân tích biến động giá theo mùa hoặc theo chiến dịch khuyến mãi.

[2] Guardian và Watsons bật cơ chế chống bot nên không cập nhật tự động được. Nhóm giữ nguyên nguyên tắc không vượt rào và chấp nhận dùng dữ liệu thu thập ban đầu của hai nguồn này.

[3] Mô hình dự đoán giá còn thiếu các đặc trưng quan trọng như thành phần, công dụng, xuất xứ và kênh phân phối, nên hệ số R^2 mới đạt khoảng 0,54.

[4] Việc đối chiếu cùng một sản phẩm giữa các nhà bán lẻ mới dừng ở mức ứng viên, chưa đủ tin cậy để so sánh giá chéo.

[5] Phiên đăng nhập được lưu trong bộ nhớ nên khởi động lại server thì phải đăng nhập lại; server đang dùng là server phát triển của Flask.

9.3. Hướng phát triển

- Bật lịch thu thập tự động chạy hằng ngày để tích lũy lịch sử giá đủ dài, từ đó phân tích biến động theo thời gian và dự báo xu hướng giá.
- Mở rộng sang các nhà bán lẻ cho phép thu thập, hoặc liên hệ xin phép và sử dụng API chính thức của Guardian và Watsons.
- Hoàn thiện việc đối chiếu sản phẩm giữa các nhà bán lẻ để xây dựng chức năng so sánh giá chéo và cảnh báo khi một nơi bán rẻ hơn hẳn.
- Bổ sung đặc trưng từ mô tả sản phẩm bằng kỹ thuật xử lý ngôn ngữ tự nhiên nhằm cải thiện độ chính xác của mô hình dự đoán giá.
- Triển khai thực tế bằng máy chủ WSGI (waitress hoặc gunicorn), bật HTTPS và lưu phiên đăng nhập vào cơ sở dữ liệu.

TÀI LIỆU THAM KHẢO

[1] SQLite Consortium, SQLite Documentation, https://www.sqlite.org/docs.html

[2] Pallets Projects, Flask Documentation, https://flask.palletsprojects.com/

[3] Scikit-learn Developers, Scikit-learn User Guide, https://scikit-learn.org/stable/user_guide.html

[4] F. T. Liu, K. M. Ting, Z. Zhou, "Isolation Forest", IEEE International Conference on Data Mining, 2008.

[5] P. J. Rousseeuw, "Silhouettes: a graphical aid to the interpretation and validation of cluster analysis", Journal of Computational and Applied Mathematics, 1987.

[6] Chart.js Contributors, Chart.js Documentation, https://www.chartjs.org/docs/latest/

[7] Robots Exclusion Protocol, RFC 9309, https://www.rfc-editor.org/rfc/rfc9309.html

PHỤ LỤC A. HƯỚNG DẪN CÀI ĐẶT VÀ CHẠY

Yêu cầu: Python 3.9 trở lên. Không cần cài đặt máy chủ cơ sở dữ liệu.

Việc cần làm	Cách thực hiện
Chạy website	Windows: nháy đúp run.bat. macOS hoặc Linux: ./run.sh
Truy cập	Mở http://127.0.0.1:5000/ (script tự mở trình duyệt)
Đăng nhập	admin / Admin@123 (quản trị viên) hoặc user / User@123 (người dùng)
Tắt server	stop.bat hoặc ./stop.sh
Khởi động lại sau khi cập nhật mã nguồn	restart.bat hoặc ./restart.sh
Khôi phục dữ liệu gốc	reset.bat hoặc ./reset.sh
Dựng lại CSDL từ dữ liệu gốc	python source-code/pipeline/build_database.py --force
Kiểm tra lại CSDL	python source-code/pipeline/verify_database.py
Huấn luyện lại mô hình	pip install -r source-code/pipeline/requirements-ml.txt rồi python source-code/pipeline/train_models.py
Chạy kiểm thử backend	python source-code/tests/test_api.py (tương tự với test_backup.py và test_crawler.py)

PHỤ LỤC B. CẤU TRÚC THƯ MỤC

Thư mục	Nội dung
source-code/backend/	app.py — API Flask và phục vụ giao diện
source-code/frontend/	9 trang HTML, CSS và JavaScript, thư viện Chart.js lưu cục bộ
source-code/crawler/	crawl.py — công cụ thu thập dữ liệu đa nguồn
source-code/pipeline/	schema.sql, build_database.py, train_models.py, verify_database.py, queries.sql
source-code/analysis/	Phân tích khám phá dữ liệu và dashboard ngoại tuyến
source-code/tests/	Kiểm thử backend và kiểm thử giao diện
dataset/raw/	Dữ liệu gốc dạng CSV
dataset/crawl/	Các lần thu thập bằng công cụ, kèm dữ liệu thô
dataset/beautyprice.db	Cơ sở dữ liệu SQLite
dataset/models/	Các mô hình đã huấn luyện

Thư mục	Nội dung
reports/	Báo cáo, tài liệu thiết kế, test case và bằng chứng demo