ĐỒ ÁN · PHÂN TÍCH DỮ LIỆU LỚN TRONG KINH DOANH

# BeautyPrice Intelligence

Thu thập, phân tích và dự đoán giá mỹ phẩm từ 5 nhà bán lẻ trực tuyến tại Việt Nam

Nhóm «số nhóm» · 5 thành viên
GVHD: «Điền họ tên giảng viên»
Mã học phần ABDA433708 · Tháng 10/2026

# Bài toán và mục tiêu

### Vấn đề thực tế

- Cùng một sản phẩm, giá chênh lệch nhiều giữa các website
- Khuyến mãi thay đổi liên tục, khó theo dõi thủ công
- Thiếu bức tranh tổng hợp để định giá và theo dõi đối thủ

### Mục tiêu của nhóm

- Tổng hợp dữ liệu 5 nhà bán lẻ vào một CSDL thống nhất
- Làm sạch, chuẩn hóa và kiểm chứng được dữ liệu
- Dự đoán giá, phân khúc và phát hiện giá bất thường
- Đưa toàn bộ lên website có phân quyền

**5.657**
**Sản phẩm**
từ 5 nhà bán lẻ

**6.350**
**Bản ghi giá**
có lịch sử theo thời gian

**6.673**
**Đánh giá**
của khách hàng

**418**
**Thương hiệu**
sau khi gộp cách viết

*Phạm vi: 6 danh mục chăm sóc da và cơ thể · dữ liệu thu thập 18–21/10/2026*

# Kiến trúc hệ thống bốn tầng

1

### Thu thập

crawl.py lấy dữ liệu từ API và HTML công khai, lưu dữ liệu thô để truy vết

2

### Làm sạch & lưu trữ

build_database.py chuẩn hóa và nạp vào SQLite, ghi nhật ký từng bước

3

### Phân tích & học máy

train_models.py huấn luyện 4 nhóm mô hình, ghi kết quả vào CSDL

4

### Ứng dụng web

Flask API và 9 màn hình giao diện, có đăng nhập và phân quyền

### Một cơ sở dữ liệu duy nhất nối cả bốn tầng

- dataset/beautyprice.db — SQLite, 17 bảng và 2 view, khoảng 9,3 MB: chép thư mục dự án sang máy khác là chạy được
- Mỗi tầng đều ghi lại dấu vết: dữ liệu thô dạng nén, nhật ký làm sạch etl_log, nhật ký thu thập collection_logs

# Công cụ thu thập dữ liệu đa nguồn

| Nguồn | Cách lấy dữ liệu | Kết quả |
|---|---|---|
| Hasaki | API JSON công khai website tự dùng | Giá và đánh giá |
| Cocolux | API JSON danh sách sản phẩm | Giá và đánh giá |
| Thế Giới Skin Food | API JSON nền tảng Haravan | Giá |
| Guardian | Phân tích HTML trang danh mục | Giá (đợt đầu) |
| Watsons | Kiểm tra truy cập | Bị chặn — ghi nhận blocked |

### Nguyên tắc thu thập

- Đọc và tuân thủ robots.txt
- Giãn cách tối thiểu 1 giây mỗi yêu cầu
- Website chặn bot thì dừng, không vượt rào
- Tên người đánh giá chỉ lưu dạng rút gọn

### Điểm đáng chú ý

Mã sản phẩm sinh bằng SHA-256 từ cặp (nhà bán lẻ, liên kết), trùng công thức với dữ liệu gốc — nên mỗi lần thu thập mới hệ thống tự nối tiếp lịch sử giá thay vì tạo sản phẩm trùng. Công cụ chạy được cả bằng dòng lệnh lẫn ngay trên website, có lịch tự động.

# Làm sạch và chuẩn hóa dữ liệu

| Vấn đề phát hiện | Cách xử lý | Tác động |
|---|---|---|
| Thương hiệu viết nhiều kiểu | Gộp theo khóa chuẩn hóa | 1.611 SP → còn 418 thương hiệu |
| % giảm giá trên web sai lệch | Tính lại từ hai mức giá | 4.861 bản ghi |
| Rating = 0 nhưng là chưa có đánh giá | Ghi NULL thay vì 0 | 864 bản ghi |
| Thiếu giá niêm yết | Để NULL, không đoán 0% | 1.489 bản ghi |
| Đánh giá nối sai theo tên gần đúng | Nối theo mã sản phẩm ở nguồn | 6.588 / 6.673 đánh giá |
| Tên có ký tự vô hình | Chuẩn hóa Unicode NFC | 43 sản phẩm |

### Minh bạch quy trình

Mỗi bước làm sạch ghi một dòng vào bảng etl_log: tên bước, bảng, số dòng vào, ra và bị tác động. Người chấm xem lại được ngay trên trang Báo cáo.

### Kiểm chứng độc lập

verify_database.py đọc thẳng CSV bằng Python thuần, tự tính lại rồi so với kết quả SQL. Hiện tất cả các mục đều PASS.

*Phần lớn công sức của đồ án nằm ở khâu làm sạch và kiểm chứng, không phải ở khâu dựng mô hình.*

# Thiết kế cơ sở dữ liệu

1 **Danh mục nền**

retailers · categories

2 **Dữ liệu nghiệp vụ**

products · product_categories · price_snapshots · reviews · review_links

3 **Vận hành hệ thống**

users · app_settings · collection_logs · etl_log

4 **Kết quả học máy**

ml_runs · ml_price_predictions · ml_clusters · ml_anomalies

### Vì sao chọn SQLite

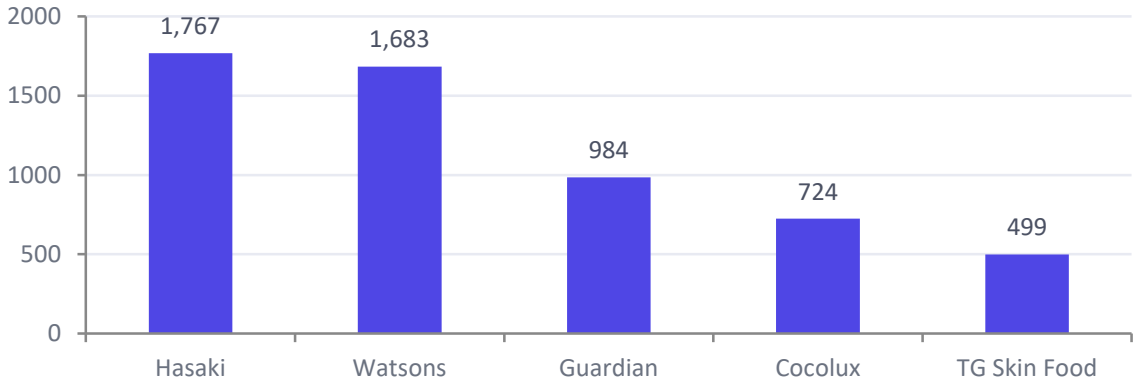
- Không cần cài máy chủ CSDL — chạy ngay khi chấm bài
- Toàn bộ CSDL là một tệp, mang sang máy khác là chạy
- Vẫn đủ khóa ngoại, CHECK, view và hàm cửa sổ

### Quy tắc nghiệp vụ quan trọng

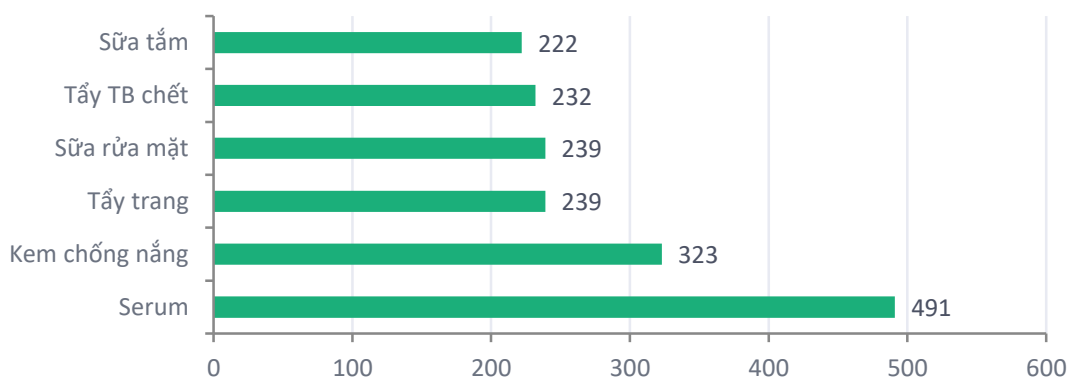
Sửa giá trên web không ghi đè bản ghi cũ mà thêm một bản ghi giá mới. Nhờ vậy lịch sử giá được giữ nguyên và biểu đồ biến động giá phản ánh đúng thực tế.

# Trực quan hóa dữ liệu

Số sản phẩm theo nhà bán lẻ




Giá trung bình theo danh mục (nghìn đ)




**8 loại biểu đồ trên 9 màn hình**

- Cột · cột ngang · cột chồng 100% · vành khuyên · đường · phân tán · bong bóng · ma trận nhầm lẫn
- Bảng màu đã kiểm tra cho người mù màu; màu gán cố định theo thực thể nên lọc dữ liệu không làm đổi màu nhóm còn lại
- Trang Báo cáo có riêng mục danh sách min – max theo danh mục, nhà bán lẻ và từng chỉ số

# Bốn bài toán học máy

#1

### Dự đoán giá bán

Học có giám sát · hồi quy

**Random Forest**

MAE 90.290 đ · $R^2$ 0,536

#2

### Phân khúc giá

Học có giám sát · phân loại

**Extra Trees**

Accuracy 73,5% · F1 0,732

#3

### Phân cụm sản phẩm

Học không giám sát

**K-Means, k = 7**

Silhouette 0,285

#4

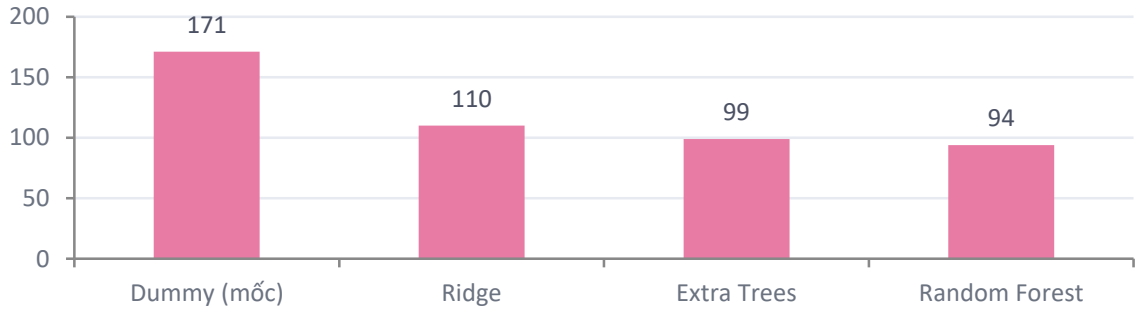
### Phát hiện bất thường

Học không giám sát

**Isolation Forest**

283 / 5.657 sản phẩm

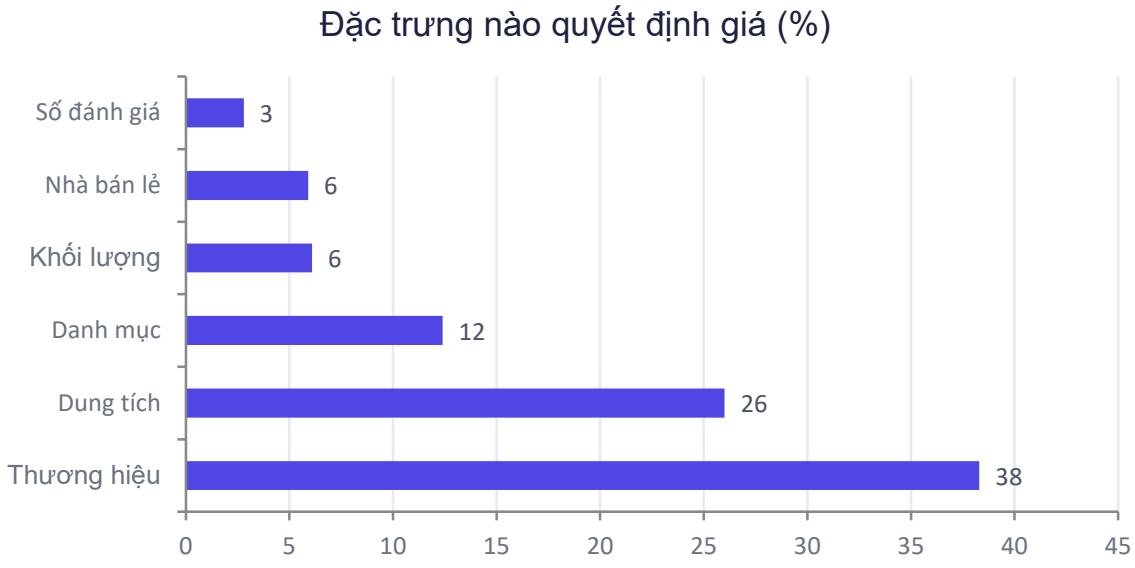
Sai số MAE trên tập validation — càng thấp càng tốt




**Cách làm bảo đảm trung thực**

- Chia 60/20/20 — chọn mô hình trên validation, chỉ báo cáo test một lần
- Ngưỡng phân khúc tính trên tập train để tránh rò rỉ
- Không dùng giá niêm yết và % giảm làm đặc trưng
- Mỗi bài toán có mô hình Dummy làm mốc so sánh

# Mô hình nói gì về thị trường




**1** **Thương hiệu quyết định giá**

Chiếm 38% độ quan trọng — người mua trả tiền cho thương hiệu nhiều hơn cho quy cách

**2** **Rating gần như vô dụng**

Dưới 3% độ quan trọng, vì 89,9% đánh giá là 5 sao nên không phân biệt được chất lượng

**3** **Hàng rẻ khó dự đoán**

Sai số 55,8% ở nhóm giá thấp, nhưng chỉ 23–27% ở nhóm trung bình và cao

Giới hạn cần nói rõ: $R^2 \approx 0{,}54$ nghĩa là mô hình giải thích được khoảng một nửa biến động giá. Phần còn lại đến từ thành phần, xuất xứ và kênh phân phối — những thông tin không có trong dữ liệu thu thập được.

# Website tích hợp toàn bộ chức năng

### Tổng quan

KPI, bộ lọc, 6 biểu đồ, nhận định tự động

### Tra cứu dữ liệu

Tìm không dấu, 5 bộ lọc, CRUD, lịch sử giá

### Phân khúc K-Means

Chọn k theo silhouette, đặc điểm từng cụm

### Dự đoán giá

So sánh mô hình, ma trận nhầm lẫn

### Phát hiện bất thường

Danh sách cần rà soát kèm lý do

### Báo cáo thống kê

Min – max, chất lượng dữ liệu, in PDF

### Thu thập dữ liệu

Chạy nền, nhật ký, lịch tự động (Admin)

### Sao lưu & phục hồi

Sao lưu, tải lên, phục hồi có kiểm tra (Admin)

| Chức năng | Người dùng | Quản trị viên |
|---|---|---|
| Xem phân tích, tìm kiếm, lọc, xuất CSV và PDF | Có | Có |
| Thêm, sửa, xóa sản phẩm | Không | Có |
| Thu thập dữ liệu, đặt lịch tự động | Không | Có |
| Sao lưu, tải lên, phục hồi dữ liệu | Không | Có |

### Phân quyền hai lớp

Giao diện ẩn nút, backend kiểm tra lại vai trò ở từng API. Sửa vai trò trong trình duyệt vẫn bị trả về đúng vai trò thật.

# Sao lưu, phục hồi và kiểm thử

1 **Sao lưu**

SQLite Online Backup API, an toàn khi web đang chạy. Kiểm tra toàn vẹn, đếm 13 bảng, tính SHA-256

2 **Trước khi phục hồi**

Đối chiếu SHA-256 để phát hiện tệp bị sửa, tự tạo bản an toàn từ dữ liệu hiện tại

3 **Phục hồi**

Ghi bản sao lưu vào CSDL đang chạy, bổ sung bảng hoặc cột mới nếu là bản cũ

4 **Sau khi phục hồi**

So số dòng 13 bảng với bản sao lưu rồi hiện bảng kết quả Khớp hoặc Lệch

| Kiểm thử | Nội dung | Kết quả |
|---|---|---|
| test_api.py | Đăng nhập, phân quyền, API, CRUD, thu thập | 6/6 |
| test_backup.py | Phục hồi thật có đối chiếu, từ chối tệp xấu | 7/7 |
| test_crawler.py | Mã sản phẩm, robots.txt, làm sạch, review | 8/8 |
| 21 test case giao diện | Chạy thật trên Chrome, tự chụp ảnh và quay video | 21/21 |

**Phục hồi được kiểm chứng thật**

Kịch bản kiểm thử xóa một sản phẩm để giả lập mất dữ liệu, rồi phục hồi và đối chiếu độc lập từng bảng. Kết quả: 13/13 bảng khớp và sản phẩm đã xóa xuất hiện lại.

# Nhận định về dữ liệu

**75,9%**
**Sản phẩm đang giảm giá**
giảm trung vị 25%

**240 N**
**Giá trung vị**
trung bình 313 nghìn

**89,9%**
**Đánh giá là 5 sao**
điểm TB 4,90

**418**
**Thương hiệu**
top 8 chỉ chiếm 21,5%

### Giảm giá là trạng thái bình thường, không phải ngoại lệ

Ba phần tư sản phẩm đang giảm giá. Hasaki khuyến mãi 97,2% sản phẩm, Guardian chỉ 52,2%. Giá niêm yết ở nhiều nơi mang tính tham chiếu hơn là giá bán thật.

### Thị trường phân mảnh, không ai thống trị

418 thương hiệu nhưng top 8 chỉ chiếm 21,5% số sản phẩm. Cocoon dẫn đầu cũng chỉ có 5,3%.

### Điểm đánh giá gần như mất khả năng phân biệt

Gần 90% đánh giá là 5 sao nên không dùng để so sánh chất lượng được. 65,5% sản phẩm còn chưa có rating nào.

*Giá lệch phải mạnh nên nhóm dùng trung vị thay cho trung bình khi mô tả mặt bằng giá.*

# Đối chiếu với yêu cầu đề bài

| Yêu cầu | Kết quả thực hiện | Trạng thái |
|---|---|---|
| Thiết kế mô hình quan hệ, chọn hệ quản trị CSDL | SQLite — 17 bảng, 2 view, đầy đủ ràng buộc | Đạt |
| Làm sạch, chuẩn hóa, có chương trình hỗ trợ | build_database.py + verify_database.py kiểm chứng độc lập | Đạt |
| Dashboard, min – max, biểu đồ đa dạng | 9 màn hình, 8 loại biểu đồ, mục min – max riêng | Đạt |
| Học không giám sát | K-Means và Isolation Forest | Đạt |
| Học có giám sát dự đoán giá trị mục tiêu | Hồi quy giá và phân loại phân khúc, mỗi bài so sánh 4 mô hình | Đạt |
| Website tích hợp, đăng nhập và phân quyền | 9 màn hình, 2 vai trò, kiểm tra hai lớp | Đạt |
| Công cụ thu thập đa nguồn (điểm cộng) | 5 nguồn, chạy từ website, có lịch tự động | Đạt |
| Tìm kiếm và lọc (điểm cộng) | Tìm không dấu, 5 bộ lọc kết hợp | Đạt |
| CRUD dữ liệu quan trọng (điểm cộng) | Thêm, sửa, xóa; sửa giá giữ lịch sử | Đạt |
| Kết xuất báo cáo ra tập tin (điểm cộng) | CSV ở 4 màn hình và in hoặc lưu PDF | Đạt |

**Bốn chức năng điểm cộng của đề bài đều đã thực hiện.**

# Hạn chế và hướng phát triển

## Hạn chế

- Dữ liệu gốc chỉ trải trên 4 ngày, chưa đủ phân tích biến động theo mùa
- Guardian và Watsons bật chống bot nên không cập nhật tự động được
- Thiếu đặc trưng về thành phần, xuất xứ, kênh phân phối nên $R^2$ mới đạt 0,54
- Đối chiếu cùng sản phẩm giữa các nhà bán lẻ mới ở mức ứng viên
- Phiên đăng nhập lưu trong bộ nhớ; đang dùng server phát triển của Flask

## Hướng phát triển

- Bật lịch thu thập hằng ngày để tích lũy lịch sử giá đủ dài, từ đó dự báo xu hướng
- Mở rộng sang nhà bán lẻ cho phép thu thập, hoặc xin phép dùng API chính thức
- Hoàn thiện đối chiếu sản phẩm để so sánh giá chéo và cảnh báo nơi bán rẻ hơn
- Khai thác mô tả sản phẩm bằng xử lý ngôn ngữ tự nhiên để cải thiện dự đoán giá
- Triển khai thật bằng waitress hoặc gunicorn, bật HTTPS

# Cảm ơn thầy cô và các bạn đã lắng nghe

Nhóm sẵn sàng trả lời câu hỏi và demo trực tiếp hệ thống

**Mã nguồn:** github.com/Mthu06/beautyprice-analytics

Tài khoản demo: admin / Admin@123 · user / User@123